PREPOZNAVANJE OBLIKA I OBRADA SKLIKE

KLASIFIKACIJA SLIKA KORISTEĆI KONVOLUCIONE NEURONSKE MREŽE

CNN

SADRŽAJ

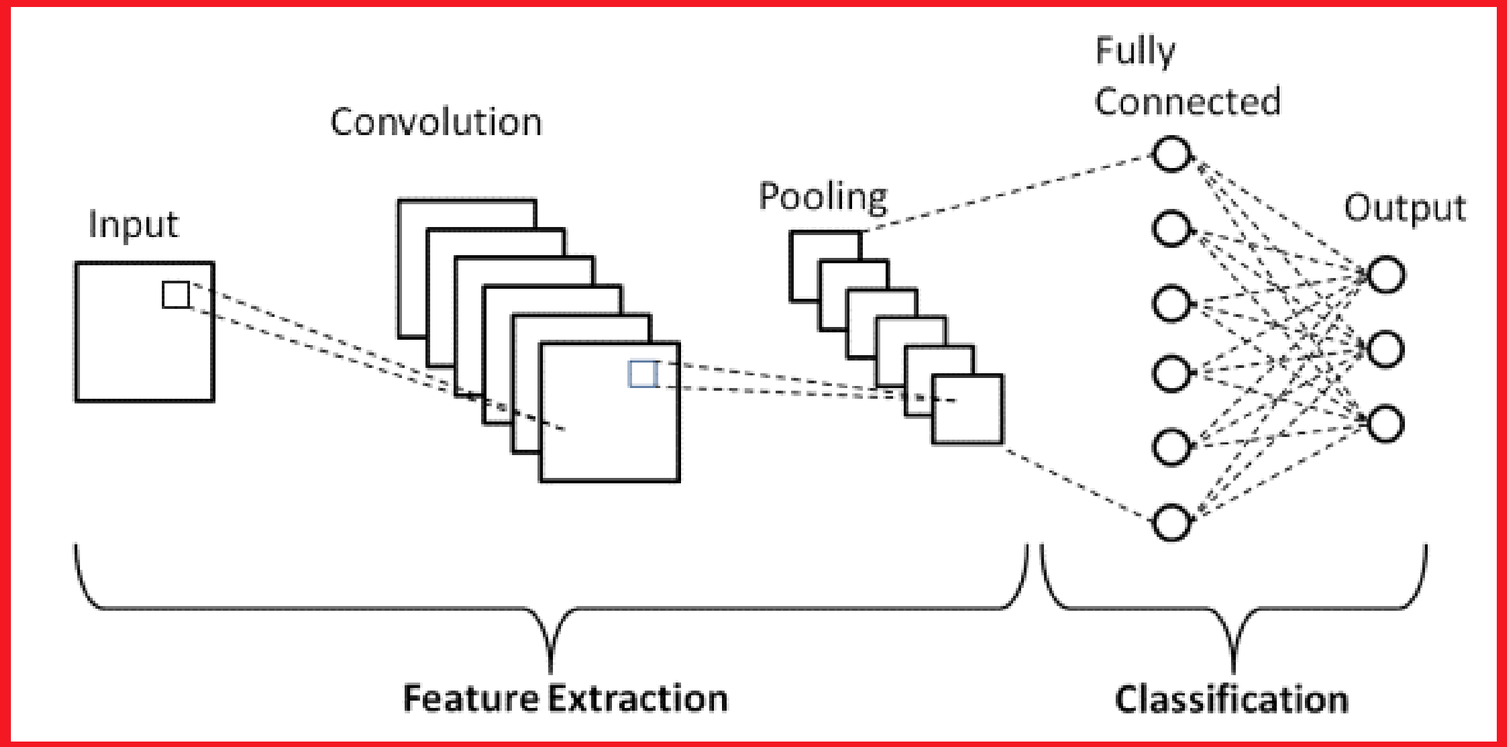
- Uvod
- Arhitektura
- Treniranje
- Najpoznatije CNNs

UVOD



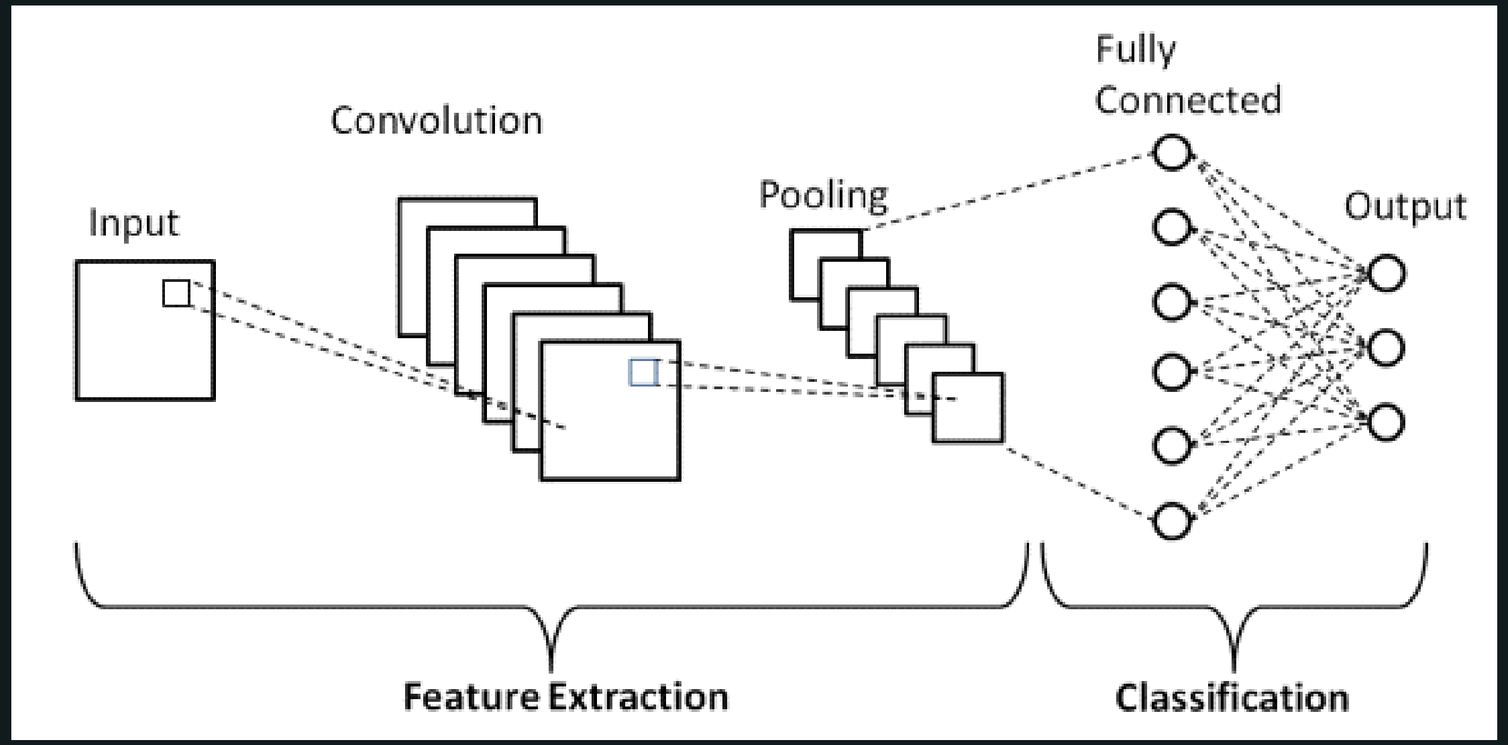
O CNN

- srž dubokog učenja
- specifično dizajnirane za procesiranje i analizu vizuelnih podataka poput slika i videa
- proces: dataset, formiranje i evaluacija modela, treniranje, testiranje



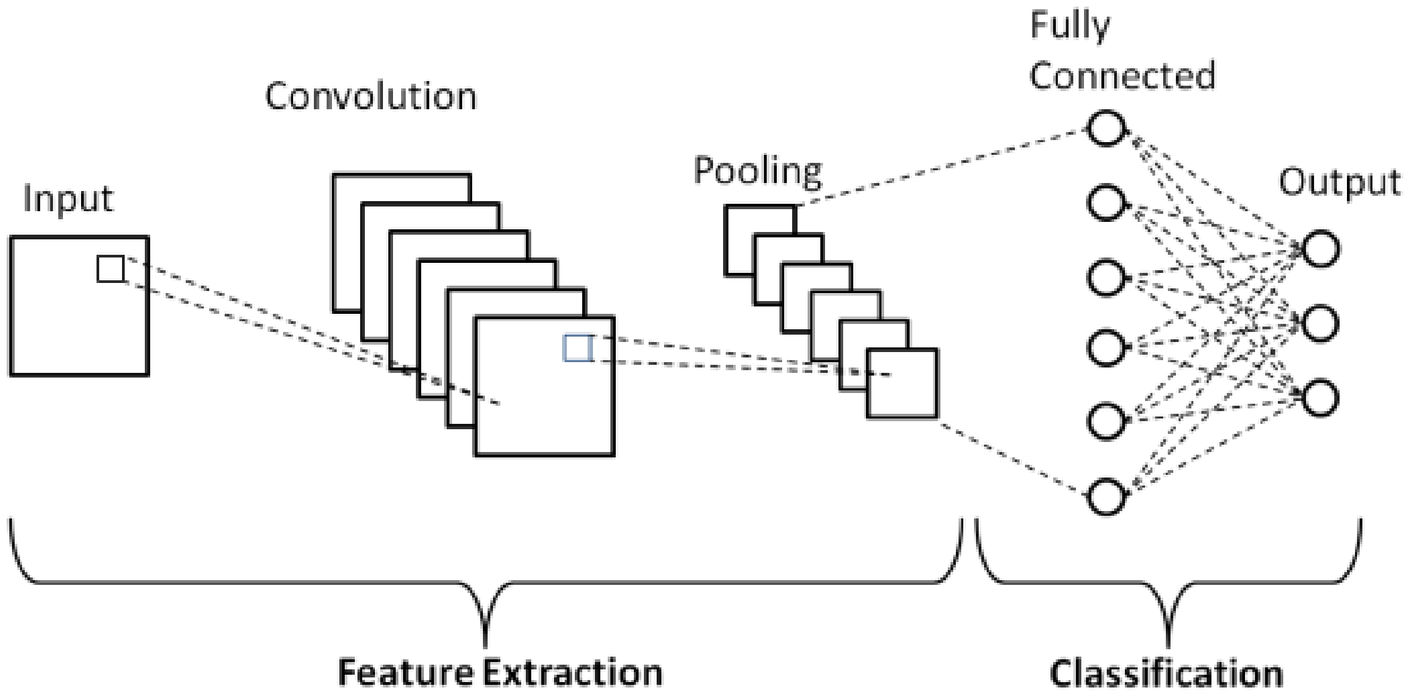
ARHITEKTURA

CNN



SLOJEVI

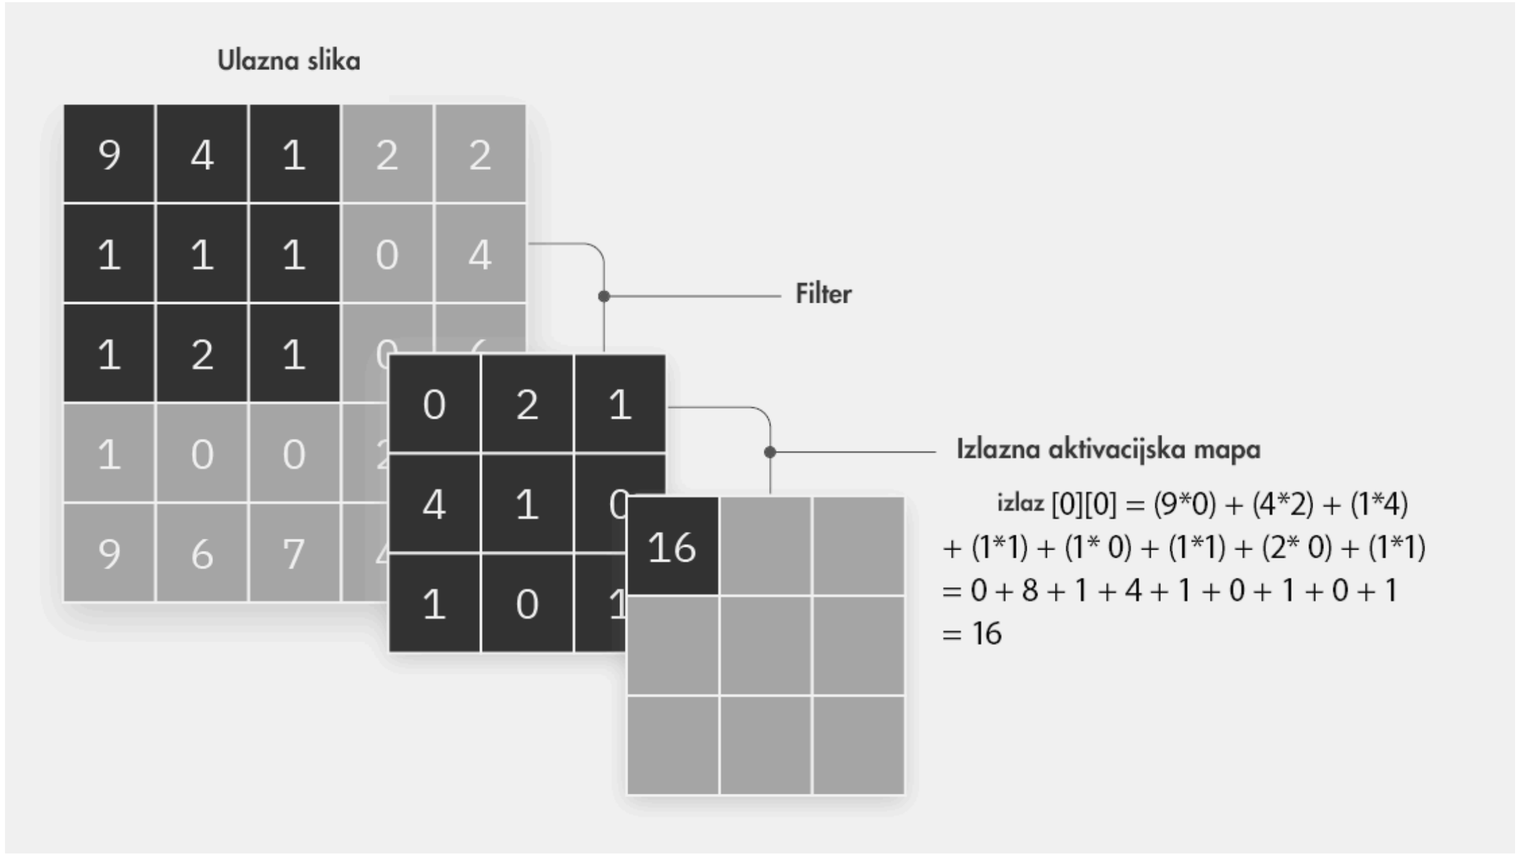
- ULAZNI: slika
- KONVOLUCIJSKI SLOJEVI
- SLOJEVI AKTIVACIJSKIH FUNKCIJA
- POOLING SLOJEVI
- FLATTEN
- POTPUNO POVEZANI SLOJEVI
- SOFTMAX-SIGMOID AKTIVACIJSKA FUNKCIJA
- IZLAZ: vjerovatnoće za sve klase



SLOJEVI

KONVOLUCIJSKI I POOLING: ekstrakcija značajki
POTPUNO POVEZANI: klasifikacija

Raniji slojevi prepoznaju jednostavne karakteristike poput boja i ivica, a kasniji sve kompleksnije paterne.



KONVOLUCIJA

- Prolaz filtera (kernela) preko ulazne slike, pri čemu se elementi filtera množe s odgovarajućim elementima slike, pa se rezultati sabiraju kako bi stvorili izlaznu mapu značajki.
- Automatska ekstrakcija relevantnih informacija iz vizualnih podataka.

Odabir hiperparametara

01

KERNEL

Manje dimenzije:
- dublje mreže
- više učenja
- prepoznavanje lokalnih detalja

Neparne dimenzije:
- postojanje centralnog elementa
- prepoznavanje simetrije i orijentacije u podacima

Najčešće:
- 3x3
- 5x5

Težine kernela su ključni parametri koji se uče tokom treniranja

02

STRIDE

- Pomak za koji se kernel pomijera tokom procesa konvolucije.
- Slična logika efekta kao kod dimenzija kernela.
- Često ne veći od 2.

03

PADDING

- bolje procesiranje ivica slike
- očuvanje dimenzija uzlaza na izlazu

Tipovi:
- valid (no padding)
- same (da bude ista dimenzija)
- full (da se poveća dimemzija)

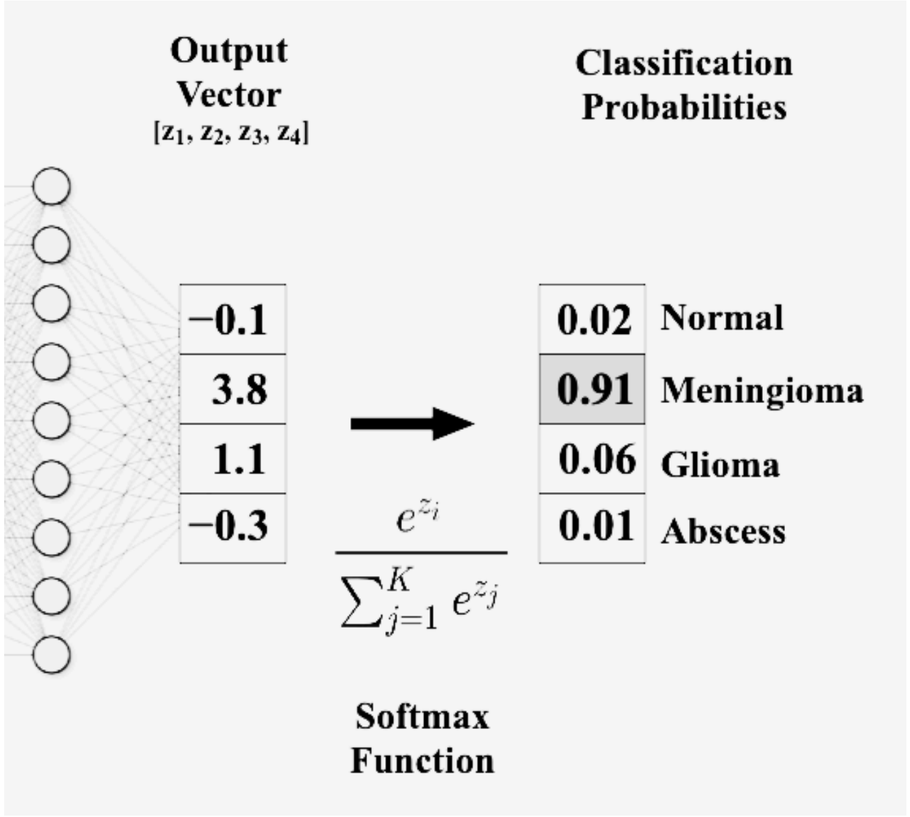
Količina proširivanja kod *same* tipa:
- (K-1)/2

DIMENZIJA IZLAZA

- (W-K+2P)/S + 1

AKTIVACIJSKE FUNKCIJE

- Primjena neke funkcije nad svakim elementom mape značajki nakon konvolucije
- U međuslojevima npr. ReLu
- U izlaznom trebaju svesti vrijednosti na 0 do 1, npr. Sigmoid za binarnu klasifikaciju i Softmax za višeklasnu

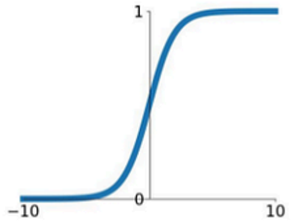


RAZLOZI ZA KORIŠTENJE

- Uvođenje nelinearanosti u model
- Većina stvarnih pojava se ne može opisati linearnom funkcijom
- Bez njih su sve operacije (moženje, sabiranje i sl. linearne) pa bi se čitav model mogao svesti na jedan sloj i mogućnost učenja bi bila veoma ograničena
- Bez njih bi gradijent uvijek bio konstantan ili ne bi postojao

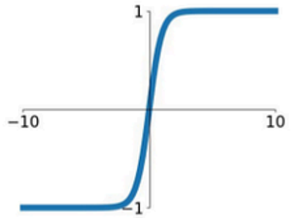
Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$



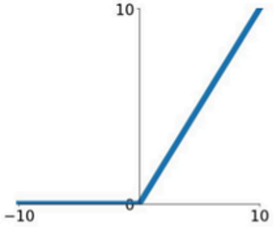
tanh

$$\tanh(x)$$



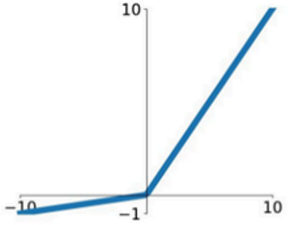
ReLU

$$\max(0, x)$$



Leaky ReLU

$$\max(0.1x, x)$$

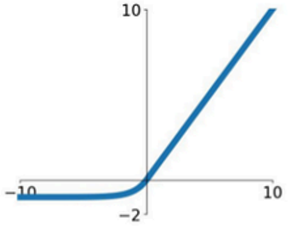


Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



Najčešće korištene aktivacijske funkcije u CNN

POOLING SLOJEVI

Prelazak filtera preko ulaza i biranje jedne od vrijednosti (npr. maksimalne ili prosječne) koje filter u tom trenutku prekriva.

- Danas se više koristi max pooling, prije više avg pooling
- Filter nema težine
- Logika oko dimenzija slična kao za kernel konvolucije
- Najčešće danas 2x2

01

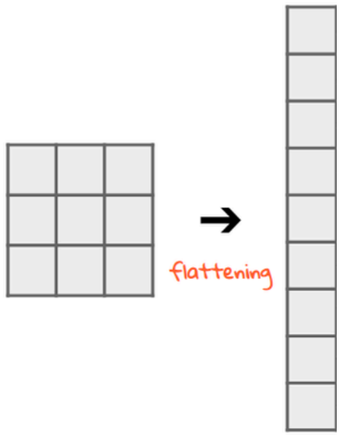
- smanjuju dimenzionalnost
- smanjuju složenost
- smanjuju broj parametara
- povećavaju efikasnost

02

- umanjuju overfitting jer se dalje procesiraju samo sumarizirane značajke, a ne svi detalji
- gube se nerelevantne informacije

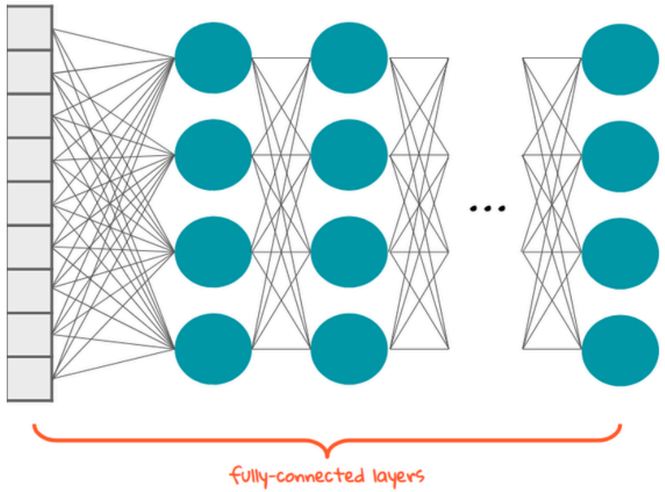
POTPUNO POVEZANI SLOJEVI

KLASIFIKACIJA



FLATTEN

Elemente svih matrica na njegovom ulazu "naslaže" jedne na druge i time proizvede jednodimenzionalni izlaz

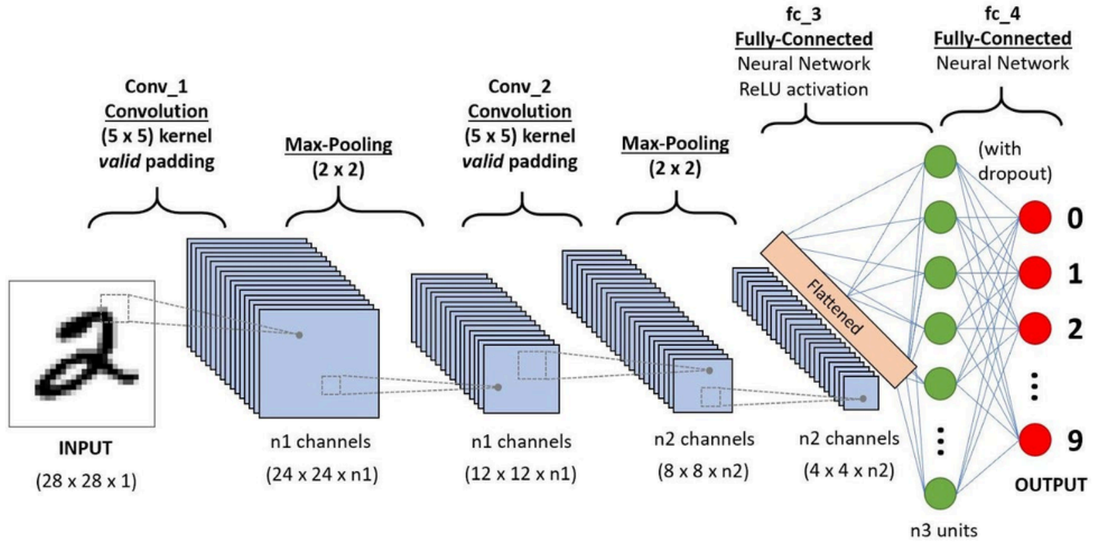


OBIČNA NEURONSKA MREŽA

ULAZ: izlaz iz flatten sloja
MEĐUSLOJEVI: potpuno povezani neuroni
IZLAZ: vjerovatnoće za sve klase

Treniranje CNN

1. Dovesti sliku iz trening skupa na ulaz mreže.
2. Izvršiti konvoluciju filtera i ulazne matrice kako bi se generirala mapa karakteristika.
3. Primijeniti aktivacijsku funkciju (npr. ReLu) nad dobivenom mapom.
4. Primijeniti pooling operaciju nad izlaznom mapom.
5. Ponoviti korake 2 do 4 u više slojeva.
6. Dobivene mape karakteristika svesti na jednu dimenziju (flatten) i proslijediti potpuno povezanom sloju radi klasifikacije.
7. U posljednjem sloju izračunati vjerovatno će pripadnosti ulaza za sve klase (npr. aktivacijska funkcija Softmax).
8. Izračunati gubitak/grešku i gradijent u odnosu na sve parametre koji se mogu naučiti (npr. težine kernela i neurona u potpuno povezanim slojevima, bias-i).
9. Propagirati pogrešku natrag i ažurirati parametre.
10. Izvršiti prolazak unaprijed i ponoviti korake 2 do 9 koristeći ažurirane parametre dok mreža ne konvergira.



NAJPOZNATIJE CNN ARHITEKTURE

01 LeNet-5

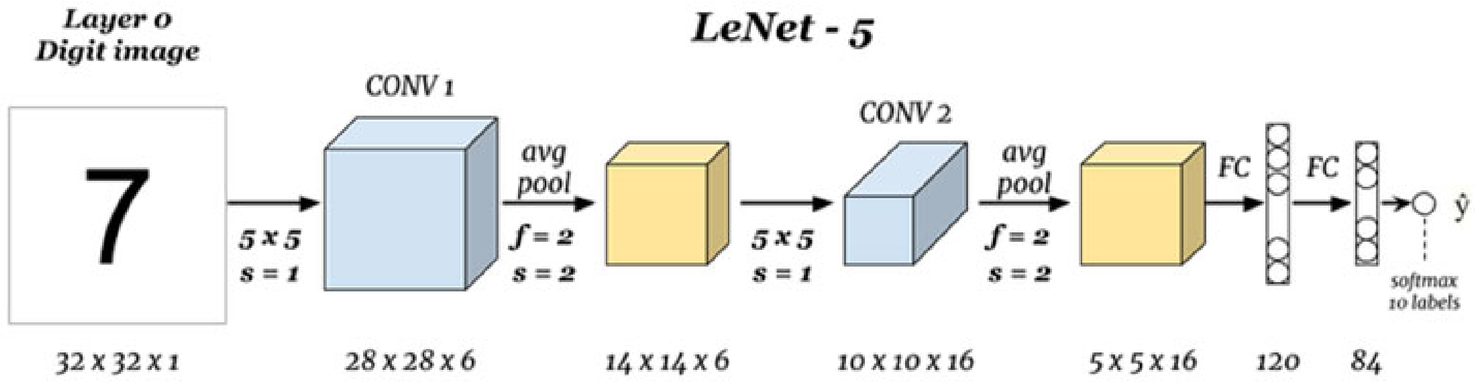
02 AlexNet

03 VGG-16

03 ResNet

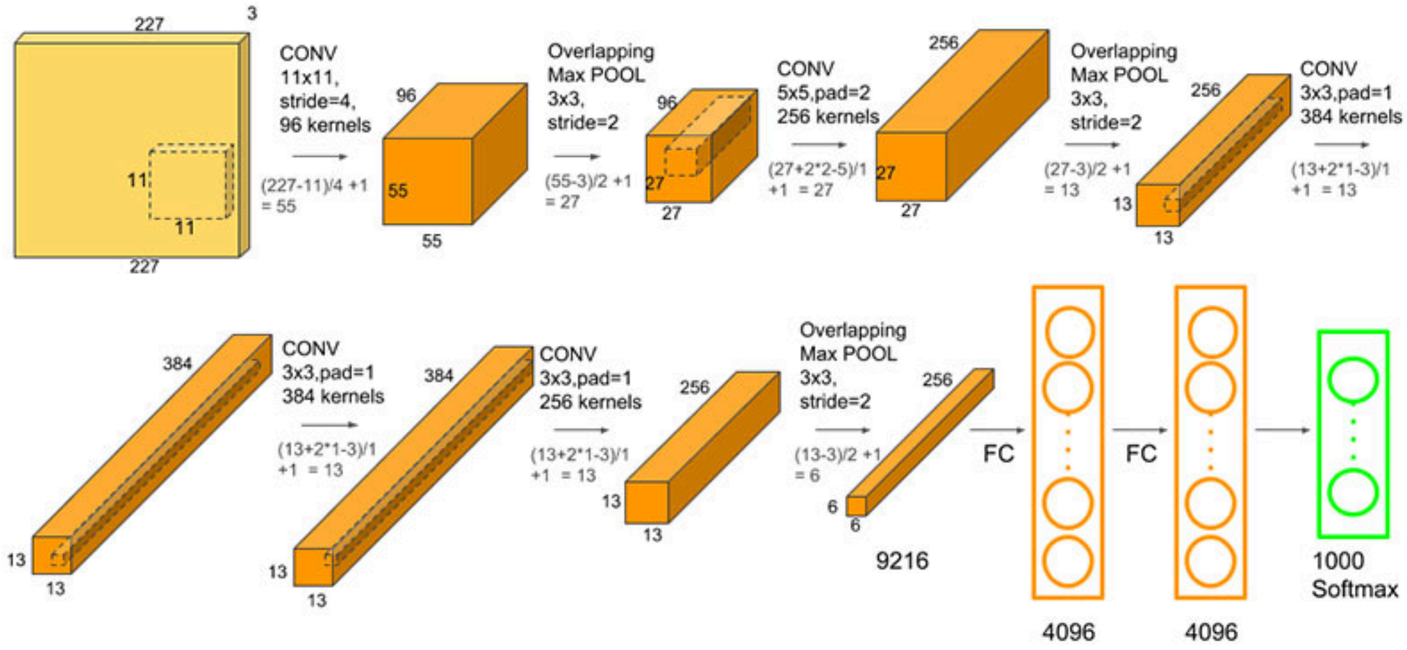
LeNet-5

- Yann LeCun 1998.
- MNIST digits dataset
- pionirska arhitektura u zadatku prepoznavanja slika



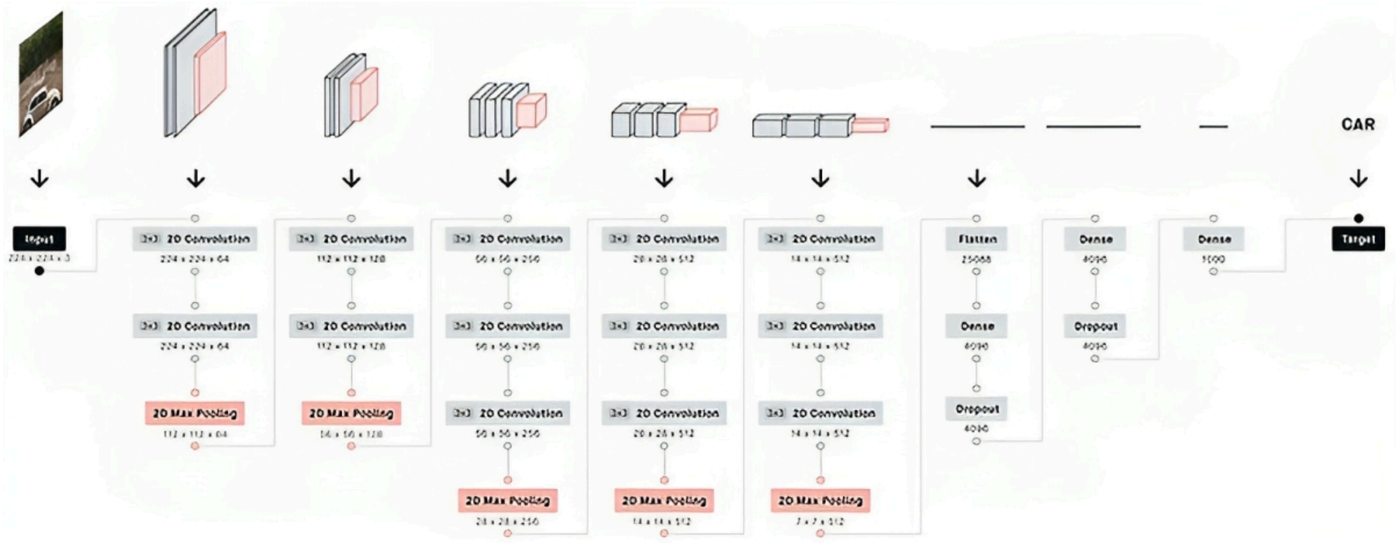
AlexNet

- 2012. godine kreirali Alex Krizhevsky, Ilya Sutskever i Geoffrey Hinton
- ImageNet skup podataka za potrebe ILSVRC (ImageNet Large Scale Visual Recognition Challenge) takmičenja
- Velika uloga u popularizaciji dubokih konvolucionih neuronskih mreža.



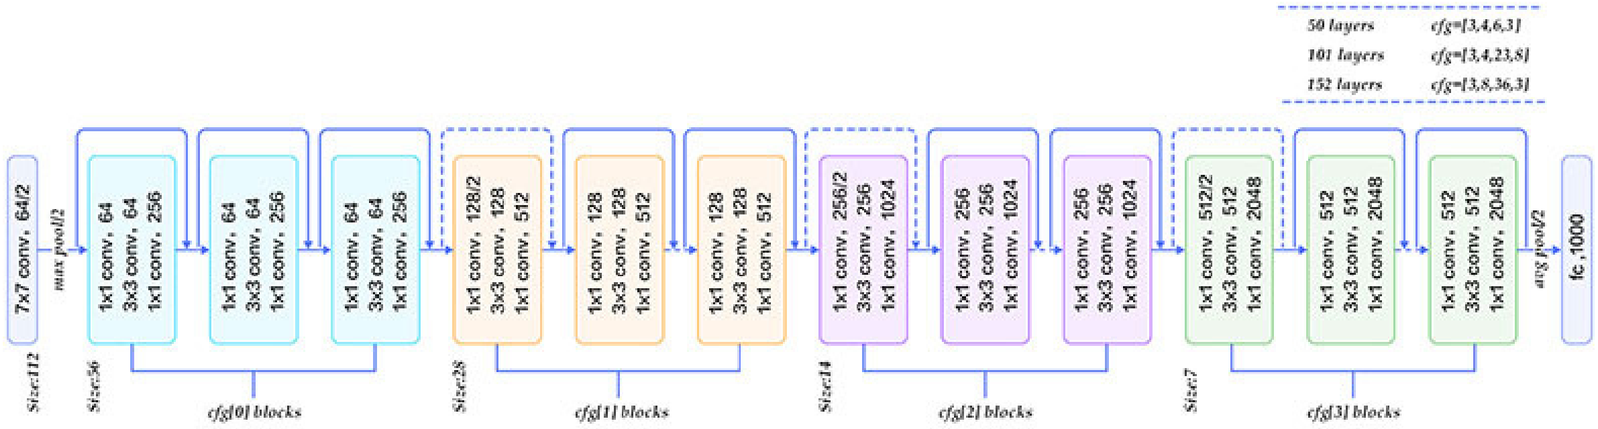
VGG-16

- VGG-16 arhitekturu su 2014. godine predložili istraživači VGG (Visual Geometry Group) sa Oxford univerziteta
- Za isti dataset ImageNet i takmičenje kao i AlexNet.
- Ova mreža se sastoji od 13 konvolucijskih i tri potpuno povezana sloja sa malim dimenzijama filtera (3x3).
- Specifična po više konvolucijskih slojeva jednih za drugim.



ResNet

- 2015. godine osmislili Kaiming He, Xiangyu Zhang, Shaoqing Ren i Jian Sun
- Isti dataset ImageNet i takmičenje kao i prethodna dva
- Uvođenje preskakajućih veza (skip connections) koje su olakšale treniranje veoma dubokih mreža.



ZAKLJUČAK

- CNN revolucionizirale više naučnih polja
- Važnosti pojedinih slojeva
- Dublje mreže su trend i radi se na otklanjanju problema koji mogu nastati (overfitting, teško treniranje i sl.)